Sistema de Recomendación FNN

Made with GAMMA

Sistema de Recomendación FNN (TOP-3)

Producción | Corte 2025-11-09

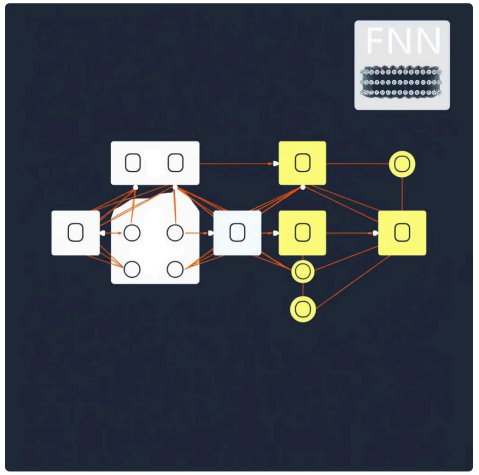

Made with GAMMA

Análisis Exploratorio de Datos – Distribución de la Variable Objetivo

El análisis exploratorio inicial se centra en la variable objetivo, que indica la ocurrencia de una compra futura. La distribución de esta variable clave revela un desbalance significativo entre las clases, un patrón común en contextos de negocio donde las transacciones de compra son eventos menos frecuentes que la ausencia de compra.

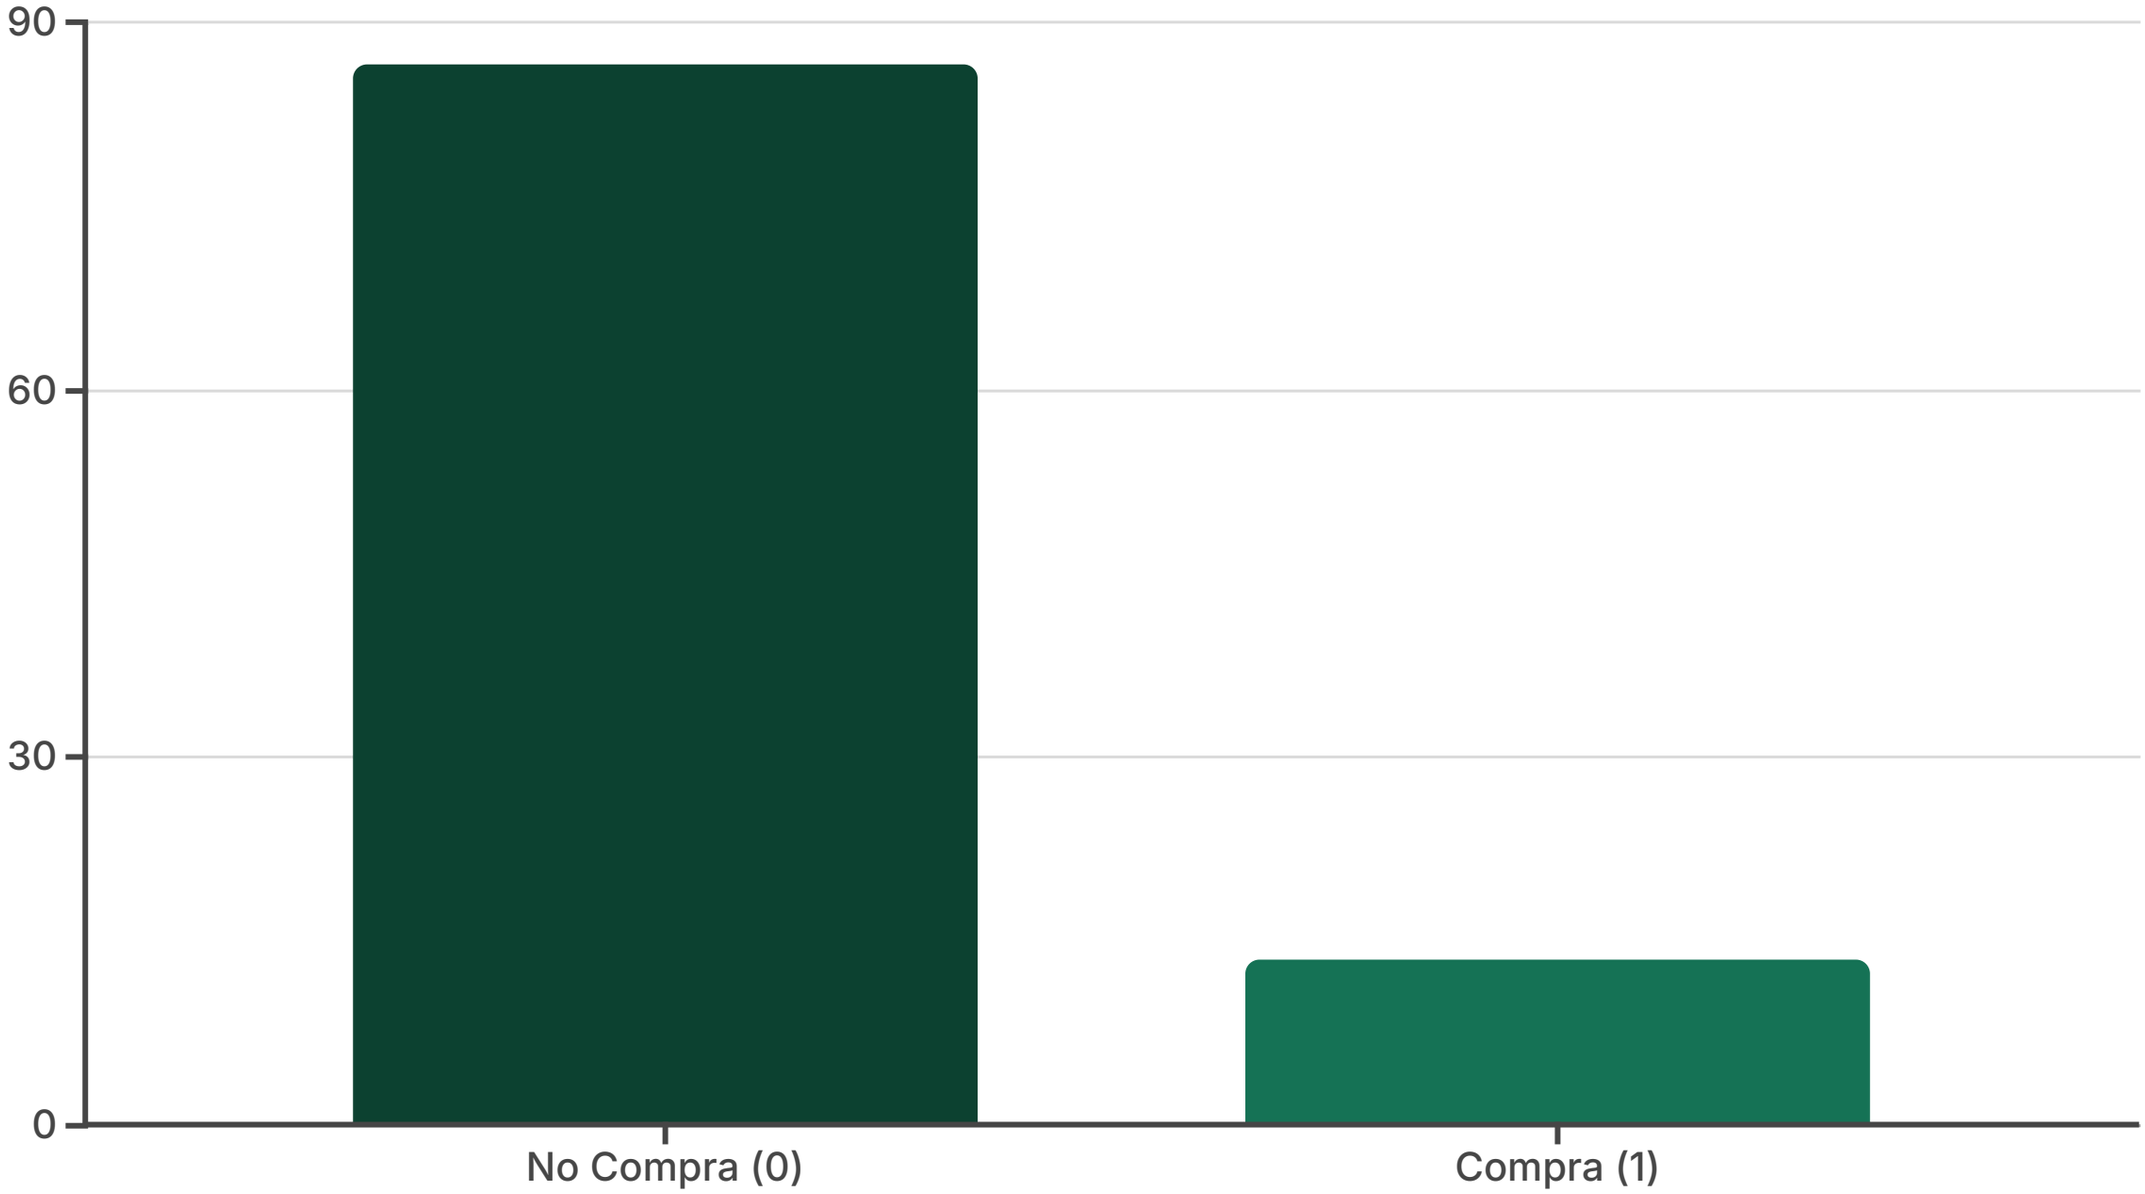

Este desbalance subraya la necesidad de un enfoque cuidadoso en el modelado, justificando la implementación de estrategias específicas para asegurar un rendimiento óptimo del sistema de recomendación.

→ **Métricas de Evaluación Robustas**

Empleo de AUC, Recall y F1-score para una evaluación más precisa, evitando métricas sesgadas por el desbalance.

→ **Compensación del Desbalance**

Uso de ponderación de clases (`pos_weight`) en la función de pérdida del modelo para dar mayor relevancia a la clase minoritaria de 'compra'.

Made with GAMMA

Flujo End-to-End del Sistema

Datos Históricos

Historico_08122025.csv

Feature Engineering

4 features: recencia, frecuencia, sow, estacionalidad

Modelo FNN

4 inputs → 64 → 32 → 1 output

Predicción TOP-3

ordenar y seleccionar top 3 por familia

Evaluación

comparar contra compras reales

Made with GAMMA

4 Features Clave del Modelo

Recencia (recencia_hl)

Intuición: Mide cuán reciente fue la última compra (1 = muy reciente, 0 = antigua)

Frecuencia (freq_score)

Intuición: >1 compra más seguido; =1 igual; <1 menos seguido

Share of Wallet (sow_24m)

Intuición: Proporción de gasto en esa subcategoría vs total

Estacionalidad (season_ratio)

Intuición: Patrón estacional de compra en ese mes

Made with GAMMA

Baseline: Modelo Lineal

$$score = 0.4 \times recencia + 0.3 \times frecuencia + 0.1 \times sow + 0.2 \times estacionalidad$$

Resultados (Corte 2025-11-09):

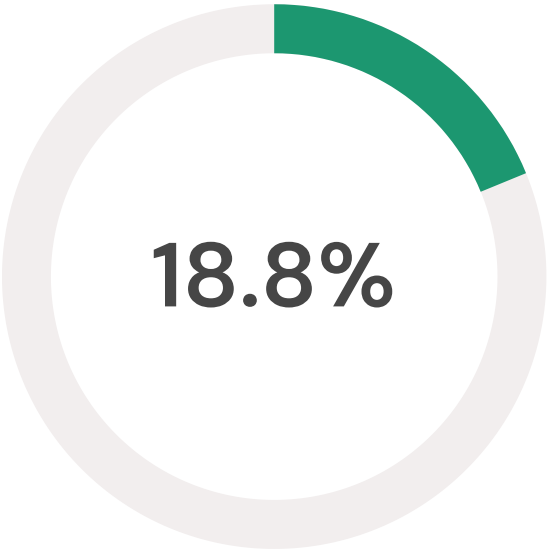

Precision@3

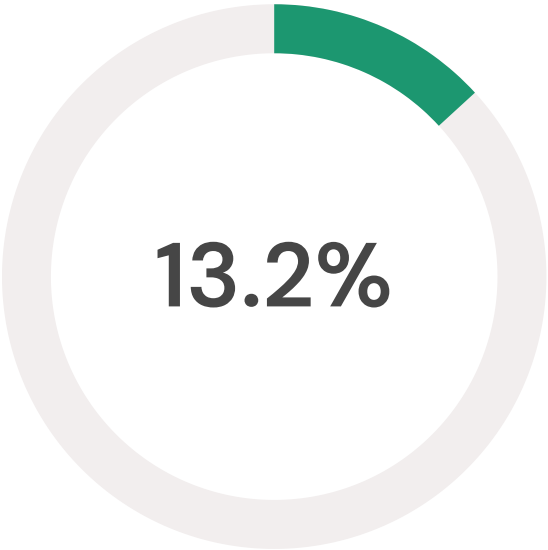

Recall@3

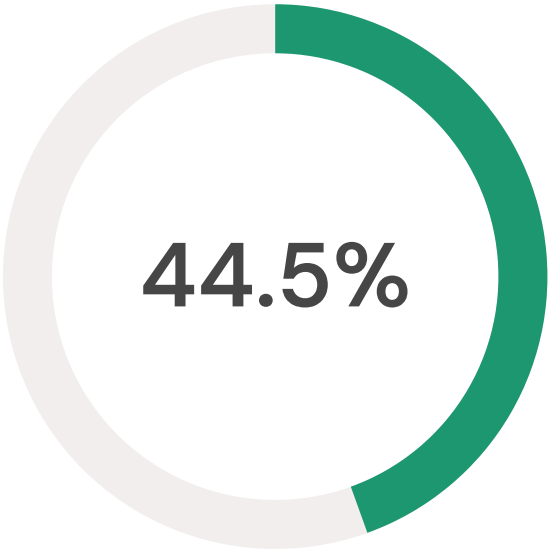

Hit Rate@3

Propósito: Referencia para comparar mejora del modelo FNN.

Made with GAMMA

Recencia

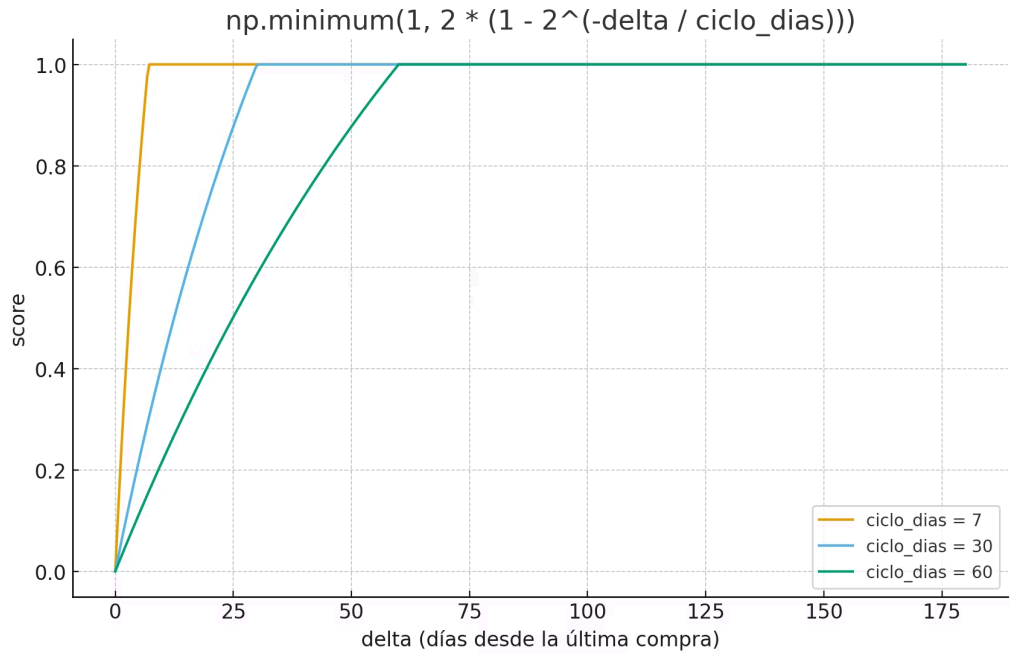

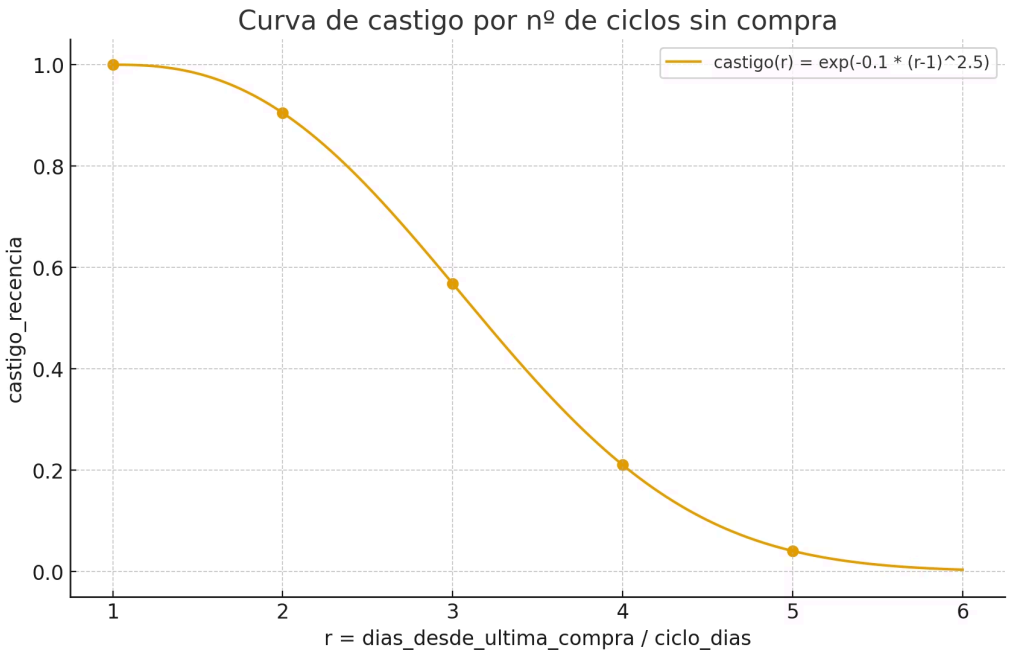

Made with GAMMA

Frecuencia

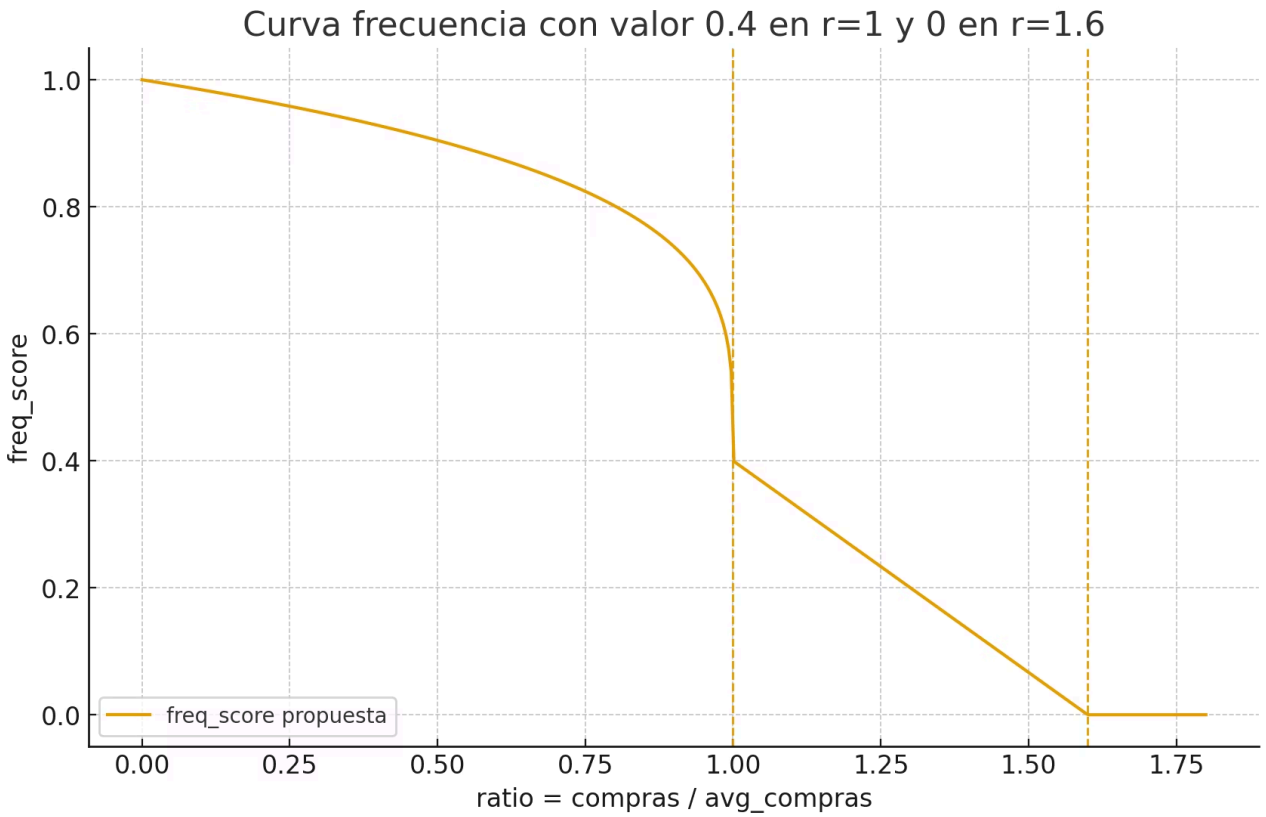

Made with GAMMA

SOW

Se cuenta el número de trasacciones que se realizo por cada subcategoria y se ve la proporción que representan estas con respecto al total de trasacciones de la famila, luego se rescala el valor de modo que sea 1 para la subcategoria que mas gasta la familia y el resto su correspondiente proporcional.

Estacionalidad

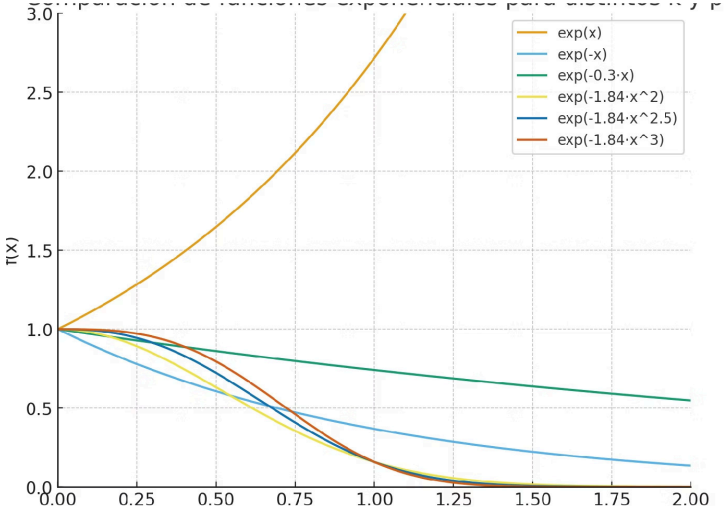

Made with GAMMA

Construcción del Dataset y Arquitectura FNN

Construcción del Dataset

01

Período de Features (Histórico menos últimos 21 días)

- Se utilizó el histórico COMPLETO MENOS los últimos 21 días (Nov 10-30).
- En este período se calcularon las 4 features: recencia, frecuencia, SOW, estacionalidad.
- Esto asegura que las features sean "limpias" sin contaminar con el período de evaluación.

02

Período de Target (Nov 10-30)

- Los últimos 21 días se reservaron EXCLUSIVAMENTE para calcular el TARGET.
- TARGET = 1: Si la familia compró esa subcategoría en Nov 10-30.
- TARGET = 0: Si la familia NO compró esa subcategoría en Nov 10-30.

03

Dataset Final

- Cada fila = (familia, subcategoría, 4 features, target).
- Total: 60,205 registros.
- Ejemplo:
  Familia 100045509 | Subcat 9353 | recencia=0.933 | freq=1.33 | SOW=0.20 | season=1.0 | TARGET=1
  Familia 100045509 | Subcat 9278 | recencia=0.450 | freq=0.80 | SOW=0.10 | season=0.5 | TARGET=0

Arquitectura FNN

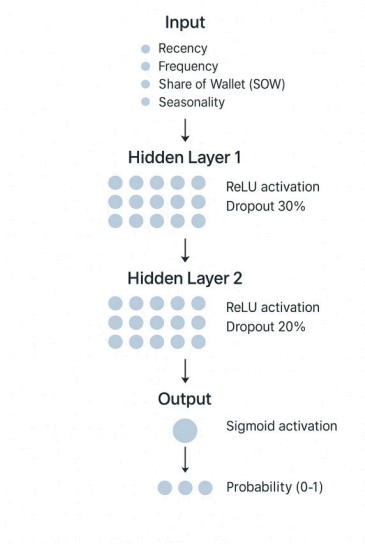

Made with GAMMA

Entrenamiento del Modelo FNN

Dataset

Total: 60,205 registros (corte de features al 2025-11-09)

Split 80/20: Train 48,164 | Test 12,041

Configuración

Normalización: Estandarización (mean=0, std=1) usando scaler

Epochs: Hasta 100 con early stopping

Resultado: Terminó en 55 epochs

Loss Final

Train Loss	0.2273
Val Loss	0.2257
Gap	0.0016 (excelente convergencia, sin overfitting)

Made with GAMMA

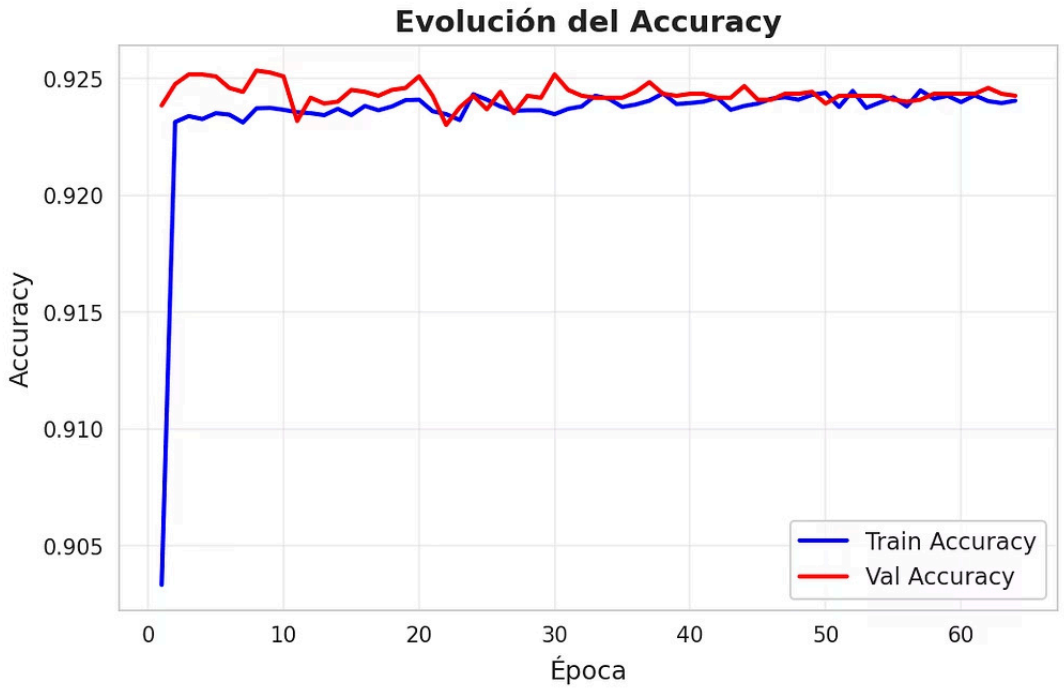

Final: 0.2255

Made with GAMMA

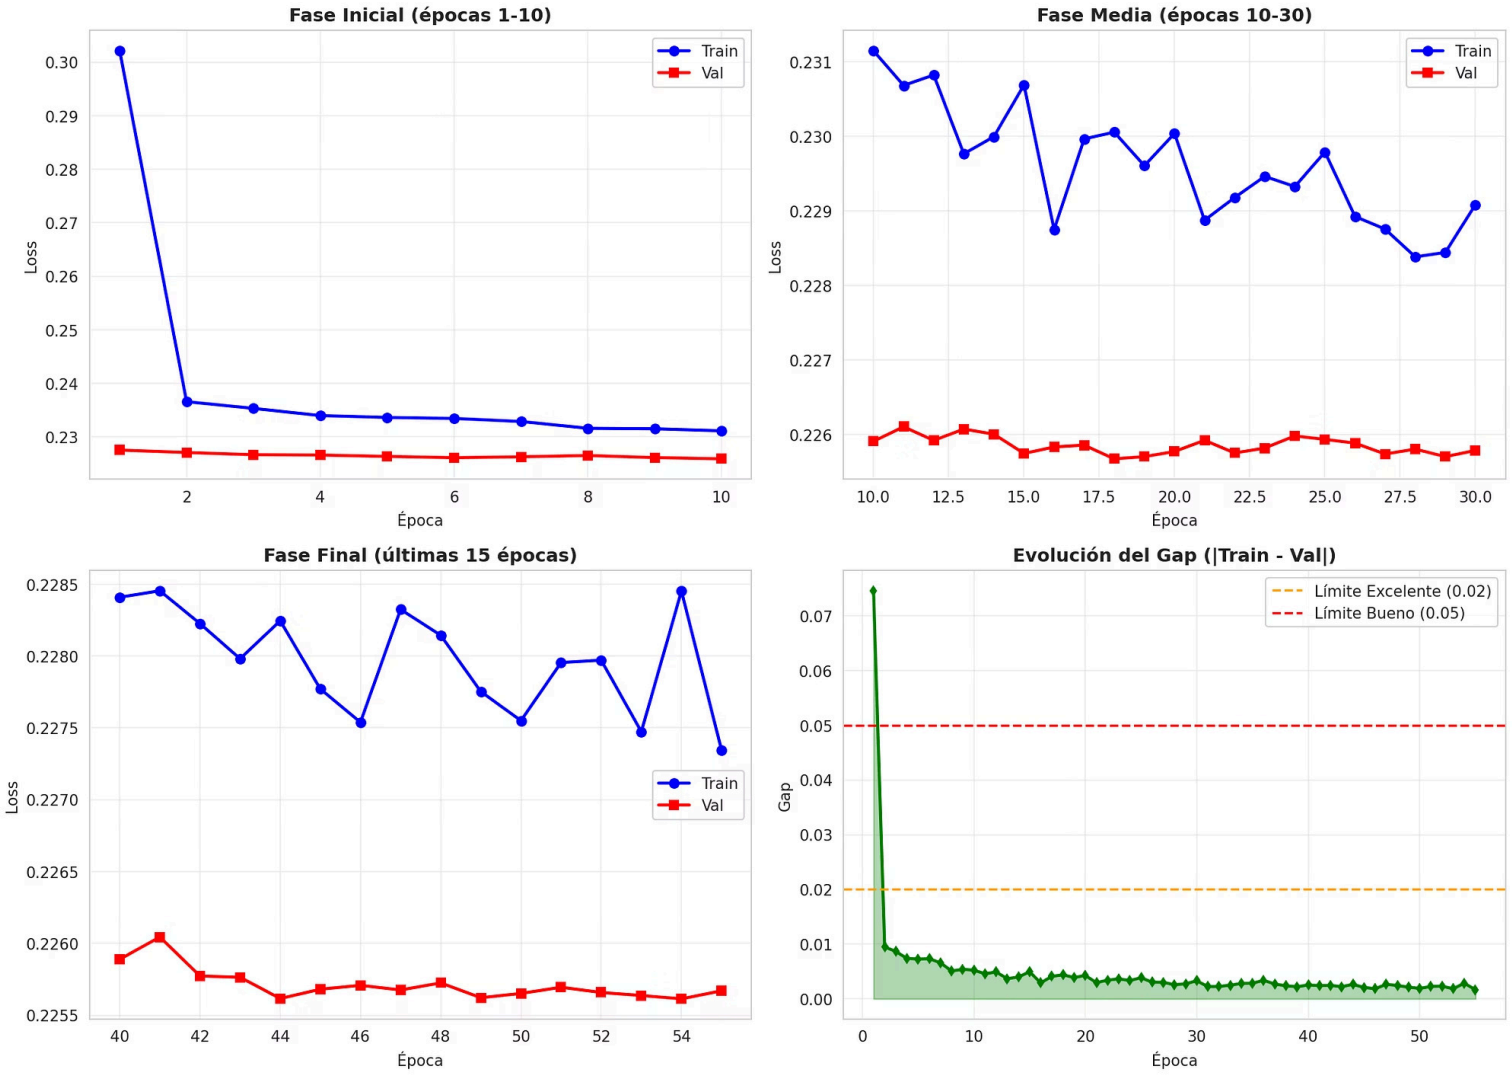

Made with GAMMA

Resumen Ejecutivo

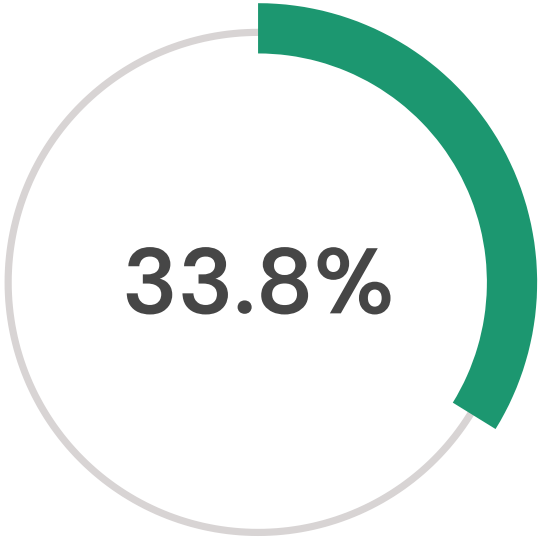

Precision@3

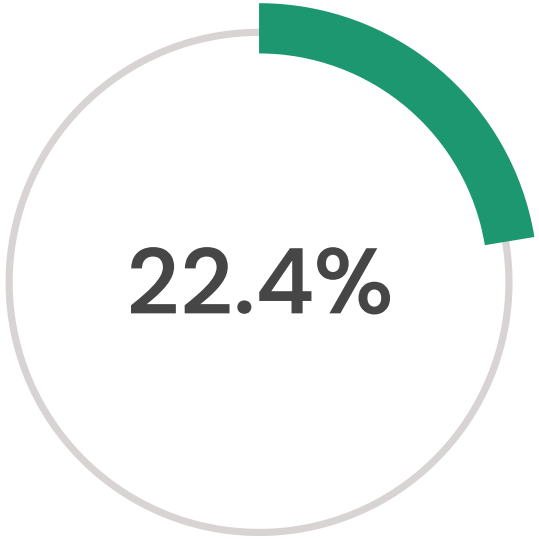

Recall@3

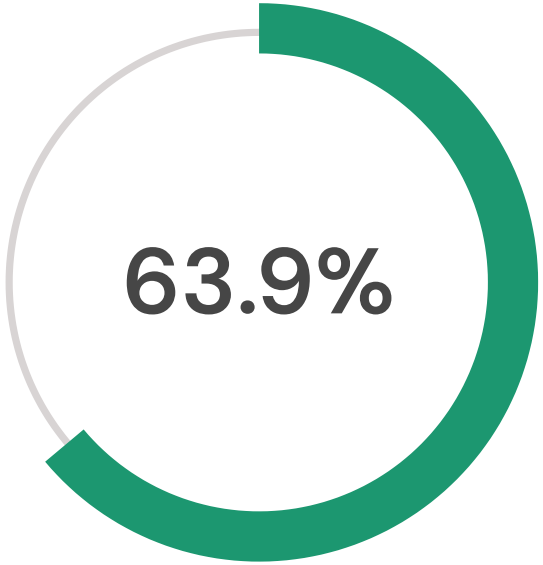

Hit Rate@3

Mejora vs Baseline (Linear): +79.7% Precision | +70.0% Recall | +43.5% Hit Rate

Made with GAMMA

Evaluación: Proceso TOP-3

Predecir Probabilidad

Para todas las subcategorías de cada familia.con las caracteristicas calculadas con el dataset completo.

Seleccionar TOP-3

Las 3 con mayor probabilidad,por familia por subcategoría.

Comparar

Contra compras reales (2025-12-01 a 2025-12-09).

Métricas

Precision@3

Proporción de recomendaciones TOP-3 que fueron compradas.

Recall@3

Proporción de compras reales que estaban en TOP-3.

Hit Rate@3

Porcentaje de familias con al menos 1 acierto en TOP-3.

Made with GAMMA

Resultados: Linear vs FNN (Corte 2025-11-09)

Métrica	Linear	FNN	Mejora
Precision@3	18.8%	33.8%	+79.7%
Recall@3	13.2%	22.4%	+70.0%
Hit Rate@3	44.5%	63.9%	+43.5%

El modelo FNN supera significativamente al baseline lineal en todas las métricas, demostrando la capacidad de la red neuronal para capturar relaciones no lineales en los datos de compra.

Made with GAMMA

Limitaciones Actuales del Sistema

Calidad de Núcleos Familiares

Clasificación de familias puede no ser perfecta. Posible "ruido": Personas agrupadas incorrectamente. Impacto: Features calculados sobre grupo incorrecto → Predicciones menos precisas

Dataset Reducido

Solo 600 familias en entrenamiento. Ideal: 10,000+ familias para generalización robusta. Impacto: Modelo no ve suficiente variedad de comportamientos

Features Limitados

Actualmente: 4 características principales. Falta crítica: Cantidad de ítems comprados por ocasión. Ejemplo: Si compra 3 paquetes de papel → Ciclo se extiende 3x. Sistema actual no diferencia entre "compró 1" vs "compró 10"

Arquitectura de Red Neuronal Básica

Red relativamente simple, sin optimización de hiperparámetros. No se probaron: Stacking, ensemble de modelos, arquitecturas avanzadas

Made with GAMMA

Oportunidades de Mejora - Nivel 2 (Estratégico)

🎯 Productos

Volver al concepto de PPMI en donde se tenia la relación entre cada item.

- Matriz PPMI por Cluster de Clientes.

👥 Perfiles de Clientes

Agrupar por patrones similares. Utilizar algormitmos de Clusterización para poder tener clientes módelos y recomendaciones independientes entre distintas clases de clientes.

⚡ Red Neuronal

Hiperparámetros + Ensemble + Embeddings. Impacto: +10-15% adicional. Meta: 45-50% Precision@3

Made with GAMMA

Ejemplos de Sistemas de Recomendación en la Industria

Amazon - Product Recommendation System

Sistema de recomendación de productos basado en patrones de compra y comportamiento del usuario.

Link: https://github.com/tmoesl/product-recommendation-system

ItemKNN (Item-based k-Nearest Neighbors)

Algoritmo que recomienda productos basándose en la similitud entre items.

Link: https://arxiv.org/html/2407.13531v1

Made with GAMMA

Aplicación: Estrategia '+ uno'

Timing Correcto y posible perdida de ventas.

Recomendaciones cuando la familia está por volver a comprar (basado en caracterisitcas históricas de compra).

Necesidad Real

No estamos ofreciendo nuevos posibles poductos de compra sino mas bien productos segun su histórico.

Precision@3 de 33.8% - 42% significa que de cada 3-3.5 productos recomendados, 1 es efectivamente comprado, validando la estrategia.

Made with GAMMA